

3.1 Modelos ARIMA

Monserrat de la Garza
A01722979

Stocks

- NVIDIA
- JNJ
- XOM

Colab link:

<https://colab.research.google.com/drive/1miWluulH9xCZvm9wGn5pR8FwpSKt7B4f?usp=sharing>

Grok: <https://grok.com/chat/f21a8692-740a-47c0-bddb-53c0e6a9bc75>

Github Link:

CHOOSE:									EXPORT
STANDARD VIEW									
SYMBOL	COMPANY	QTY	PRICE PAID	LAST PRICE	DAY'S CHANGE	MARKET VALUE	% PROFIT/LOSS		
XOM	Exxon Mobi...	100	105.50	106.49	0.86 ▲	\$10,649.00	99.00 ▲ (0.94%)	TRADE	
JNJ	Johnson & ...	100	152.49	154.84	-1.48 ▼	\$15,483.50	234.50 ▲ (1.54%)	TRADE	
AAPL	Apple Inc	10	206.90	213.03	0.53 ▲	\$2,130.29	61.28 ▲ (2.96%)	TRADE	
COST	Costco Who...	20	917.45	1,004.39	9.89 ▲	\$20,087.80	1,738.80 ▲ (9.48%)	TRADE	
WMT	Walmart Inc	100	83.37	97.66	0.41 ▲	\$9,766.00	1,429.00 ▲ (17.14%)	TRADE	
NVDA	NVIDIA Corp	100	111.64	113.53	4.61 ▲	\$11,352.99	188.99 ▲ (1.69%)	TRADE	
TSLA	Tesla Inc	97	229.43	283.44	1.28 ▲	\$27,493.63	5,238.92 ▲ (23.54%)	TRADE	

En esta actividad utilicé un nuevo código en Python para analizar cómo se comportan las acciones de JNJ, XOM y NVIDIA, pero ahora con herramientas más robustas para revisar si hay patrones, relaciones a largo plazo o si el comportamiento de estas series puede ser predecible. Este análisis es muy útil para entender mejor cómo se mueven los mercados, sobre todo cuando los datos parecen aleatorios.

Estocástico (Random Walk y ARIMA)

El código parte de la idea de que los precios siguen un comportamiento **estocástico**, es decir, aleatorio, como un *random walk*. Por eso se aplican modelos como **ARIMA**, que combinan componentes autoregresivos, de promedio móvil y diferenciación para intentar encontrar patrones útiles.

Interpretación:

- Este modelo ayuda a capturar tendencias ocultas y a hacer predicciones, siempre y cuando la serie esté bien preparada (ver estacionariedad abajo).
- En este caso, los datos fueron analizados desde archivos Excel con precios históricos para hacer esta evaluación más clara.

Estacionario (ARIMA y diferenciación)

Para poder usar ARIMA correctamente, las series deben ser **estacionarias** (que su comportamiento estadístico no cambie con el tiempo). El código aplicó diferenciación automática para convertir las series cuando esto no se cumplía.

Resultado:

- El código detectó automáticamente si una serie no era estacionaria y aplicó diferenciación (ajustando el parámetro **d** de ARIMA).
- Esto permite que el modelo se enfoque en los cambios en los precios y no en los niveles, ayudando a mejorar las predicciones.

Raíz Unitaria (ADF y KPSS)

Se usaron dos pruebas estadísticas: ADF (Augmented Dickey-Fuller) y KPSS para detectar la presencia de raíz unitaria, que indica no estacionariedad.

Interpretación:

- Si la serie tiene raíz unitaria, es inestable y necesita ser diferenciada.
- ADF busca rechazar la raíz unitaria, mientras que KPSS busca confirmarla. El código combinó ambas para una visión más completa.

Cointegración (Prueba de Johansen)

Se utilizó la prueba de Johansen para analizar si existe cointegración entre las acciones, es decir, si se mueven juntas en el largo plazo.

- **Resultado:**

- Si las acciones están cointegradas, significa que existe una relación estable entre ellas que se mantiene a través del tiempo.
- Si no están cointegradas, el modelo las analiza por separado, como series independientes.

Conclusión General

Gracias a este análisis, confirmé que el uso de pruebas estadísticas como ADF, KPSS y Johansen mejora mucho la calidad del análisis. Cuando usamos modelos como ARIMA estos requieren transformar bien los datos para funcionar correctamente. La cointegración es una herramienta poderosa para entender cómo se relacionan distintas acciones entre sí en el largo plazo.